DATA MINING

WEEK 10: DATASET, KARAKTERISTIK DATA, BOD DAN ALGORITMA KLASIFIKASI READMISSION PASIEN DIABETES

ANGGOTA TIM

Bambang Herlambang	5803024019
Benedictus Erlangga	5803024011
Robertus Geraldyn Alexandro Gabeler	5803024025

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KATOLIK WIDYA MANDALA

SURABAYA

2026

01 / Dataset dan sumber

Link dataset: https://archive.ics.uci.edu/dataset/296/diabetes-130-us-hospitals-for-years-1999-2008

Dataset memuat catatan kunjungan rawat inap pasien dengan diabetes dari 130 rumah sakit dan jaringan layanan di Amerika Serikat, periode 1999-2008. Sasaran klasifikasi adalah readmission, bukan diagnosis diabetes/non-diabetes.

Komponen	Keterangan
Sumber	UCI Machine Learning Repository, dataset 296
Pembuat / tahun	Clore, Cios, DeShazo, dan Strack (2014)
DOI	10.24432/C5230J
Lisensi	Creative Commons Attribution 4.0 (CC BY 4.0)
Berkas asli	diabetic_data.csv dan IDS_mapping.csv
Unit observasi	Satu kunjungan rawat inap; satu pasien dapat muncul beberapa kali
Jumlah aktual	101.766 baris, 50 kolom, 71.518 pasien berbeda
Struktur kolom	47 fitur (8 numerik, 39 kategorikal), 2 ID, 1 target

Contoh dan karakteristik data

02 / Contoh data aktual

Enam baris pertama berikut adalah subset kolom data asli sebelum cleaning. ID pasien dan ID kunjungan tidak ditampilkan.

Usia	Gender	Hari rawat	Jumlah obat	Rawat inap sebelumnya	HbA1c	Target
[0-10)	Female	1	1	0	None	NO
[10-20)	Female	3	18	0	None	>30
[20-30)	Female	2	13	1	None	NO
[30-40)	Male	2	16	0	None	NO
[40-50)	Male	1	8	0	None	NO
[50-60)	Male	3	16	0	None	>30

Kelompok usia berupa interval 10 tahun. number_inpatient menghitung rawat inap dalam tahun sebelumnya. None pada HbA1c menunjukkan pemeriksaan tidak dilakukan.

03 / Target dan distribusi kelas

Target asli	Makna label	Jumlah	Persen
NO	Tidak tercatat readmission	54.864	53,912%
>30	Readmission lebih dari 30 hari	35.545	34,928%
<30	Readmission kurang dari 30 hari	11.357	11,160%

Target biner awal: <30 menjadi 1; NO dan >30 menjadi 0. Kelas 0 bukan berarti pasien tidak pernah mengalami readmission. Batas label asli dipertahankan, tanpa menggantinya menjadi <=30 hari.

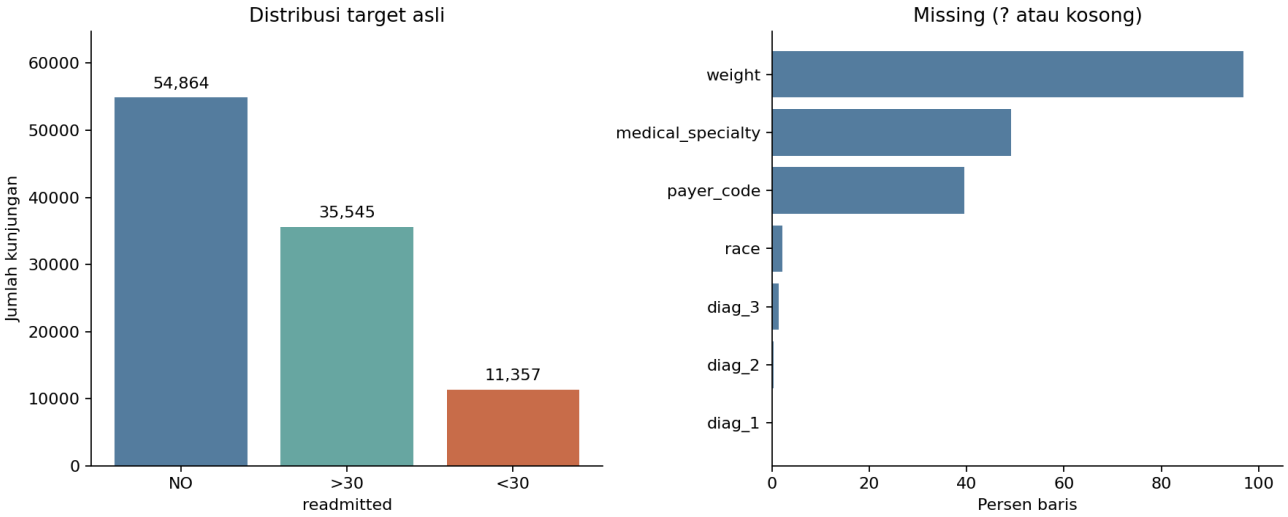
Struktur yang memengaruhi analisis

Terdapat 30.248 baris di luar kunjungan pertama setiap pasien. Tidak ditemukan duplikasi baris persis maupun duplikasi ID kunjungan. Pasien berulang tetap dipertahankan, tetapi seluruh kunjungan seorang pasien harus berada di set yang sama.

Fitur meliputi demografi, administrasi masuk/keluar, hitungan layanan, diagnosis, hasil lab dan obat. Kode diagnosis serta administrasi diperlakukan sebagai kategori, bukan angka kontinu.

Kualitas data dan implikasinya

04 / Missing value dan ketidakseimbangan kelas



Gambar 1. Distribusi target dan missing pada data asli. Missing di grafik dihitung dari tanda ? atau string kosong; kategori None pada tes lab tidak dihitung sebagai missing.

Kolom	Jumlah missing	Persen
weight	98.569	96,858%
medical_specialty	49.949	49,082%
payer_code	40.256	39,557%
race	2.273	2,234%
diag_3	1.423	1,398%
diag_2	358	0,352%
diag_1	21	0,021%

Keputusan awal penanganan

- Tidak menghapus seluruh baris yang memiliki missing karena akan menghilangkan banyak data. Kolom missing >50% pada train dikeluarkan; fitur lainnya diimputasi sesuai tipe.

- Tanda ? dan kosong menjadi missing. Gender Unknown/Invalid (3 baris) dan kode administrasi tidak diketahui dinormalisasi menjadi missing. None pada hasil lab tetap kategori tes tidak dilakukan.

- Kelas <30 hanya sekitar 11,16% data asli. Akurasi saja tidak memadai; average precision, precision, recall dan F1 perlu diperiksa.

- ID dipakai untuk audit dan split, bukan prediktor. Statistik seleksi kolom, imputasi, scaling dan encoding dipelajari hanya dari train.

BOD: masalah dan tujuan

05 / Rumusan BOD

Bagian ini memuat bahan rumusan masalah dan tujuan. Kepanjangan istilah BOD dan format akhir mengikuti penjelasan dosen.

Komponen	Rumusan proyek
Masalah	Readmission dini ingin dikenali dari karakteristik kunjungan pasien diabetes.
Pertanyaan	Apakah suatu kunjungan akan diikuti readmission yang tercatat dalam kurang dari 30 hari?
Tujuan	Membangun dan membandingkan dua algoritma klasifikasi dengan preprocessing dan split yang sama.
Target operasional	1 untuk <30; 0 untuk NO atau >30. Unit prediksi adalah satu kunjungan.
Waktu prediksi	Saat keluar rumah sakit; informasi selama kunjungan boleh digunakan.
Manfaat	Memahami pola data dan trade-off deteksi readmission dini sebagai kajian akademik.
Ruang lingkup	Data historis AS; pengujian generalisasi ke pasien berbeda melalui pembagian berbasis pasien.
Evaluasi utama	Average precision pada validation, dibandingkan baseline mayoritas.
Evaluasi pelengkap	Precision, recall, F1, ROC-AUC, balanced accuracy dan confusion matrix.
Keberhasilan awal	Pipeline berjalan tanpa overlap pasien; model nontrivial melampaui AP baseline pada validation. Skor bukan bukti manfaat klinis.

Cohort dan keterbatasan

Kunjungan dengan status keluar meninggal (kode 11, 19, 20, 21 menurut IDS_mapping.csv) dikeluarkan sebagai keputusan cohort awal, bukan aturan wajib UCI. Status hospice/transfer lain dipertahankan.

Data historis, bias representasi dan tidak adanya validasi eksternal membatasi generalisasi. Hasil tidak menunjukkan sebab-akibat atau kesiapan penggunaan klinis, dan tidak otomatis berlaku pada rumah sakit Indonesia.

Algoritma klasifikasi

06 / Dua algoritma dan baseline

Algoritma	Alasan pemilihan	Konfigurasi awal
NGBoost	Natural gradient boosting untuk probabilitas readmission; distribusi Bernoulli.	150 estimator; learning_rate=0,03; minibatch_frac=0,75; base tree depth=3, min_samples_leaf=20; seed=42
Rotation Forest	Ensemble dengan PCA pada kelompok fitur; mekanisme berbeda dari Random Forest.	20 estimator; min_group=max_group=3; remove_proportion=0,5; seed=42; n_jobs=2
DummyClassifier	Pembanding mayoritas dengan probabilitas prevalensi train; menguji nilai tambah model.	strategy=prior; label mayoritas dan probabilitas prevalensi train

Prinsip perbandingan

- Kedua model menggunakan target, cohort, train dan validation yang sama. Parameter awal ditetapkan sebelum melihat skor validation; belum merupakan hasil tuning.

- Threshold awal 0,5; tidak ada class weighting atau oversampling. Kedua model memakai SVD 32 komponen + scaling yang sama, fit hanya train. Adapter mengurangi komputasi dan memberi fitur kontinu; ablasinya masih diperlukan.

- Average precision (AP) dihitung dari probabilitas dan merangkum kurva precision-recall. AP tidak sama dengan integrasi trapezoid PR-AUC.

- Precision, recall dan F1 mengacu kelas positif <30. Confusion matrix menunjukkan false positive dan false negative, sehingga akurasi tinggi pada kelas mayoritas tidak menutupi kegagalan mendeteksi readmission dini.

- Brier score, log loss dan kurva kalibrasi melengkapi AP; model probabilistik tidak otomatis terkalibrasi. Pemilihan algoritma bukan klaim pertama pada dataset. Test disimpan untuk evaluasi final.

Rencana coding dan referensi

07 / Alur week 11-12

Tahap	Rencana pelaksanaan
Preprocessing	Normalisasi missing/kode tidak diketahui, validasi tipe/ID, keputusan cohort dan pemisahan target.
Pembagian data	GroupShuffleSplit, seed 42: sekitar 70% pasien train, 15% validation, 15% test. Proporsi baris dapat berbeda.
Transformasi	Fit pada train saja: seleksi kolom missing/konstan, imputasi, scaling dan one-hot encoding. Validation/test hanya transform.
Mining awal	Fit SVD 32 + scaling pada train, lalu latih baseline prior, NGBoost dan Rotation Forest dengan fitur yang sama.
Evaluasi awal	Nilai pada validation menggunakan AP dan metrik pelengkap; tidak memakai test untuk pemilihan model.
Lanjutan week 12	Tuning, CV berbasis pasien dan analisis kesalahan. Setiap fold mempelajari preprocessing ulang dari bagian latihnya sendiri.

Split ini tidak stratified dan bukan temporal. Distribusi kelas diperiksa per set; ID kunjungan tidak dianggap tanggal. Evaluasi menilai pasien berbeda, bukan prediksi tahun mendatang.

08 / Referensi dan keterlacakan

Dataset UCI - Clore dkk. (2014), DOI 10.24432/C5230J

NGBoost, ICML 2020 dan dokumentasi NGBClassifier

Rotation Forest, Rodriguez dkk. (2006)

Dokumentasi average precision, scikit-learn 1.7

Sumber lokal: data/raw/diabetic_data.csv dan IDS_mapping.csv. Statistik dibuat dengan python -m src.profile_data; kode ada di src/profile_data.py. Versi library tercatat pada requirements.txt dan metadata preprocessing.

SHA-256 CSV asli:
0689e7ec031237dc63031b938805c48377748761a3b26acab621567afa24df97

Lampiran berikut berisi kamus seluruh 50 kolom. Missing dihitung dari ? atau kosong pada data asli; kode tidak diketahui dan gender invalid ditangani terpisah saat preprocessing.

Lampiran: kamus data (1/4)

Kolom 1-13 dari 50 kolom CSV asli.

Kolom / peran	Deskripsi dan tipe analisis	Unik*	Missing*
encounter_id ID	ID kunjungan; metadata, bukan prediktor Tipe: kategorikal	101766	0 0.0%
patient_nbr ID	ID pasien; kelompok pembagian data, bukan prediktor Tipe: kategorikal	71518	0 0.0%
race fitur	Kategori ras yang tercatat Tipe: kategorikal	5	2273 2.234%
gender fitur	Gender yang tercatat Tipe: kategorikal	3	0 0.0%
age fitur	Kelompok usia dalam interval 10 tahun Tipe: kategorikal	10	0 0.0%
weight fitur	Kelompok berat badan; missing sangat tinggi Tipe: kategorikal	9	98569 96.858%
admission_type_id fitur	Kode jenis masuk; lihat IDS_mapping.csv Tipe: kategorikal	8	0 0.0%
discharge_disposition_id fitur	Kode status/tujuan keluar; lihat IDS_mapping.csv Tipe: kategorikal	26	0 0.0%
admission_source_id fitur	Kode sumber rujukan; lihat IDS_mapping.csv Tipe: kategorikal	17	0 0.0%
time_in_hospital fitur	Lama rawat, hari (1-14) Tipe: numerik	14	0 0.0%
payer_code fitur	Kode pembayar/asuransi Tipe: kategorikal	17	40256 39.557%
medical_specialty fitur	Spesialisasi dokter yang menerima pasien Tipe: kategorikal	72	49949 49.082%
num_lab_procedures fitur	Jumlah pemeriksaan laboratorium selama kunjungan Tipe: numerik	118	0 0.0%

* Unik = jumlah nilai unik nonmissing. Missing = tanda ? atau kosong. None pada hasil lab adalah kategori tes tidak dilakukan. ID disimpan sebagai metadata, bukan fitur.

Lampiran: kamus data (2/4)

Kolom 14-26 dari 50 kolom CSV asli.

Kolom / peran	Deskripsi dan tipe analisis	Unik*	Missing*
num_procedures fitur	Jumlah prosedur selain pemeriksaan laboratorium Tipe: numerik	7	0 0.0%
num_medications fitur	Jumlah obat berbeda selama kunjungan Tipe: numerik	75	0 0.0%
number_outpatient fitur	Jumlah kunjungan rawat jalan dalam tahun sebelumnya Tipe: numerik	39	0 0.0%
number_emergency fitur	Jumlah kunjungan gawat darurat dalam tahun sebelumnya Tipe: numerik	33	0 0.0%
number_inpatient fitur	Jumlah kunjungan rawat inap dalam tahun sebelumnya Tipe: numerik	21	0 0.0%
diag_1 fitur	Kode diagnosis utama (ICD-9); kategori, bukan angka kontinu Tipe: kategorikal	716	21 0.021%
diag_2 fitur	Kode diagnosis kedua (ICD-9) Tipe: kategorikal	748	358 0.352%
diag_3 fitur	Kode diagnosis ketiga (ICD-9) Tipe: kategorikal	789	1423 1.398%
number_diagnoses fitur	Jumlah diagnosis yang tercatat Tipe: numerik	16	0 0.0%
max_glu_serum fitur	Kategori hasil glukosa; None berarti tidak diperiksa Tipe: kategorikal	4	0 0.0%
A1Cresult fitur	Kategori hasil HbA1c; None berarti tidak diperiksa Tipe: kategorikal	4	0 0.0%
metformin fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
repaglinide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%

* Unik = jumlah nilai unik nonmissing. Missing = tanda ? atau kosong. None pada hasil lab adalah kategori tes tidak dilakukan. ID disimpan sebagai metadata, bukan fitur.

Lampiran: kamus data (3/4)

Kolom 27-39 dari 50 kolom CSV asli.

Kolom / peran	Deskripsi dan tipe analisis	Unik*	Missing*
nateglinide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
chlorpropamide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
glimepiride fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
acetohexamide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
glipizide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
glyburide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
tolbutamide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
pioglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
rosiglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
acarbose fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
miglitol fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
troglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
tolazamide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	3	0 0.0%

* Unik = jumlah nilai unik nonmissing. Missing = tanda ? atau kosong. None pada hasil lab adalah kategori tes tidak dilakukan. ID disimpan sebagai metadata, bukan fitur.

Lampiran: kamus data (4/4)

Kolom 40-50 dari 50 kolom CSV asli.

Kolom / peran	Deskripsi dan tipe analisis	Unik*	Missing*
examide fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	1	0 0.0%
citoglipton fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	1	0 0.0%
insulin fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
glyburide-metformin fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	4	0 0.0%
glipizide-metformin fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
glimepiride-pioglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
metformin-rosiglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
metformin-pioglitazone fitur	Status obat: No (tidak), Steady (tetap), Up (naik), Down (turun). Tipe: kategorikal	2	0 0.0%
change fitur	Apakah terdapat perubahan obat diabetes (Ch/No) Tipe: kategorikal	2	0 0.0%
diabetesMed fitur	Apakah obat diabetes diresepkan (Yes/No) Tipe: kategorikal	2	0 0.0%
readmitted target	Target asli: NO, >30, <30 Tipe: kategorikal	3	0 0.0%

* Unik = jumlah nilai unik nonmissing. Missing = tanda ? atau kosong. None pada hasil lab adalah kategori tes tidak dilakukan. ID disimpan sebagai metadata, bukan fitur.