DATA MINING

WEEK 11: PREPROCESSING, MINING DAN EVALUASI AWAL KLASIFIKASI READMISSION PASIEN DIABETES

ANGGOTA TIM

Bambang Herlambang	5803024019
Benedictus Erlangga	5803024011
Robertus Geraldyn Alexandro Gabeler	5803024025

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KATOLIK WIDYA MANDALA

SURABAYA

2026

01 / Tujuan dan cakupan

Menghubungkan pembacaan data, cleaning, pembagian pasien, transformasi fitur, pelatihan baseline dan dua algoritma, serta evaluasi awal. Dataset yang digunakan adalah Diabetes 130-US Hospitals for Years 1999-2008.

Komponen	Keputusan eksperimen
Unit analisis	Satu kunjungan rawat inap; pasien yang sama dapat memiliki banyak kunjungan
Target awal	<30 = 1; NO dan >30 = 0. Sasaran adalah readmission dini, bukan diagnosis diabetes
Waktu prediksi	Saat keluar rumah sakit, menggunakan informasi kunjungan yang sudah tersedia
Pembagian	Train, validation dan test berbasis pasien, seed 42
Model awal	Logistic Regression dan Random Forest; DummyClassifier sebagai baseline mayoritas
Set evaluasi	Validation saja, 15.065 baris; modul mining tidak membaca X_test/y_test
Status hasil	Percobaan satu split dan parameter awal; belum tuning, CV atau uji final

Ringkasan hasil

Data asli terdiri dari 101.766 kunjungan. Setelah cleaning/cohort, 100.114 kunjungan dipertahankan. Tidak ada pasien yang tumpang tindih antarset. Transformasi menghasilkan 1.222 fitur numerik siap model.

Average precision validation: baseline 0,1101; Logistic Regression 0,2102; Random Forest 0,2014. Hasil ini merupakan pembandingan awal, bukan bukti kesiapan penggunaan klinis.

Cleaning dan keputusan cohort

02 / Aturan yang diterapkan

Langkah	Aturan dan alasan
Pembacaan CSV	dtype=str, keep_default_na=False. Trim spasi; ? dan kosong menjadi missing. None pada hasil lab dipertahankan sebagai kategori tes tidak dilakukan.
Validasi identitas	ID kosong, target tidak dikenal, atau ID kunjungan berulang dengan isi berbeda menghentikan proses untuk review manual.
Duplikasi	Hapus baris duplikat persis bila ditemukan; pada dataset ini jumlahnya 0.
Cohort	Keluarkan kunjungan berstatus meninggal: discharge 11, 19, 20, 21 menurut IDS_mapping.csv. Ini keputusan awal proyek, bukan aturan wajib UCI.
Nilai tidak diketahui	Gender Unknown/Invalid menjadi missing. Kode administrasi tidak diketahui dinormalisasi sesuai mapping.
Fitur hitungan	Delapan fitur dikonversi numerik. Nilai negatif, non-integer atau time_in_hospital di luar 1-14 hari menghentikan proses.
Prediktor	ID pasien/kunjungan dan target asli tidak masuk X. Diagnosis dan kode administrasi tetap kategori. Nilai ekstrem valid tidak dibuang otomatis.

Dampak cleaning aktual

Pemeriksaan	Hasil
Data asli / setelah cleaning	101.766 / 100.114 baris
Kunjungan meninggal dikeluarkan	1.652
Gender invalid menjadi missing	3
Kode admission type / discharge / source menjadi missing	10.237 / 4.680 / 6.929 baris
Pasien berbeda setelah cleaning/cohort	70.439

Status hospice/transfer lain tetap dipertahankan. Kunjungan terdahulu pasien yang kemudian meninggal tidak otomatis dibuang. Perubahan cohort ini perlu dicatat saat menafsirkan hasil.

Split pasien dan transformasi

03 / Pembagian tanpa overlap pasien

Set	Baris	Pasien	Positif <30	Proporsi positif
train	70.071	49.307	7.967	11,370%
validation	15.065	10.566	1.659	11,012%
test	14.978	10.566	1.731	11,557%

GroupShuffleSplit membagi sekitar 70/15/15 persen pasien, bukan jumlah baris. Split tidak stratified dan tidak temporal. Seluruh kelas tersedia pada tiap set dan overlap pasien antarset adalah 0.

```
first = GroupShuffleSplit(
    n_splits=1, test_size=0.30, random_state=42)
train, rest = next(first.split(
    frame, groups=frame.patient_nbr))
second = GroupShuffleSplit(
    n_splits=1, test_size=0.50, random_state=42)
validation, test = next(second.split(
    frame.iloc[rest],
    groups=frame.iloc[rest].patient_nbr))
```

04 / Fit hanya pada train

Bagian	Perlakuan
Seleksi kolom	weight dibuang karena missing >50% train. acetohexamide, examide, citoglipton konstan pada train. Fitur tersisa: 43.
Numerik	Imputasi median train, kemudian StandardScaler.
Kategorikal	Imputasi __MISSING__, one-hot encoding; kategori frekuensi <10 di train digabung sebagai infrequent.
Kategori baru	Masuk kelompok infrequent jika ada, atau seluruh nol jika kelompok tersebut tidak terbentuk.
Keluaran	Matriks sparse 1.222 kolom. Validation/test hanya transform; tidak mempelajari statistik baru.

Mining: baseline dan dua model

05 / Konfigurasi awal

Model	Konfigurasi
DummyClassifier	strategy=most_frequent; selalu memprediksi kelas mayoritas.
Logistic Regression	solver=liblinear; C=1,0; max_iter=1000; class_weight=balanced; random_state=42.
Random Forest	n_estimators=150; max_depth=16; min_samples_leaf=5; max_features=sqrt; class_weight=balanced_subsample; random_state=42; n_jobs=2.

Semua model di-fit pada 70.071 baris train dengan fitur yang sama. Parameter dan threshold 0,5 ditetapkan sebelum membaca skor validation, bukan hasil tuning. Tidak ada oversampling sebelum split.

Inti pelatihan dan prediksi

```
model.fit(x_train, y_train)
positive_index = list(model.classes_).index(1)
probability = model.predict_proba(x_val)[:, positive_index]
prediction = (probability >= 0.5).astype(int)
scores = binary_metrics(y_val, probability)
```

Kode lengkap dan pemeriksaan

- src/mining.py memuat baseline, kedua estimator, ekspor model/prediksi dan laporan evaluasi. Source code pada PDF berupa cuplikan; modul di repo menjadi rujukan lengkap.

- Pelatihan Logistic Regression diperiksa terhadap ConvergenceWarning; proses dihentikan bila belum konvergen. Eksekusi yang dilaporkan selesai tanpa peringatan konvergensi.

- Transformasi, parameter model, seed, target dan hash data asli dicatat pada experiment.json. Model disimpan terpisah dari laporan agregat.

- Bobot kelas seimbang dapat mengubah trade-off precision/recall. Probabilitasnya belum dikalibrasi dan threshold ini belum merupakan threshold operasional.

Evaluasi pada validation

06 / Metrik hasil eksekusi

Metrik	Baseline	Logistic Regression	Random Forest
Accuracy	0,8899	0,6601	0,6739
Balanced accuracy	0,5000	0,6186	0,6179
Precision positif	0,0000	0,1757	0,1788
Recall positif	0,0000	0,5654	0,5461
F1 positif	0,0000	0,2681	0,2694
ROC-AUC	0,5000	0,6620	0,6674
Average precision (AP)	0,1101	0,2102	0,2014

Validation: 15.065 kunjungan, termasuk 1.659 positif <30 (11,012%). Precision, recall dan F1 mengacu kelas positif. AP/ROC-AUC memakai probabilitas, sedangkan metrik label memakai threshold 0,5.

Interpretasi hasil

- Baseline mencapai akurasi 88,99%, tetapi recall dan F1 positif bernilai 0 karena tidak memprediksi satu pun readmission dini. Akurasi saja menyesatkan pada data ini.

- Logistic Regression memiliki AP tertinggi pada percobaan awal, 0,2102, dibanding baseline 0,1101. Random Forest mencapai 0,2014. Ini belum membuktikan keunggulan stabil antar-split.

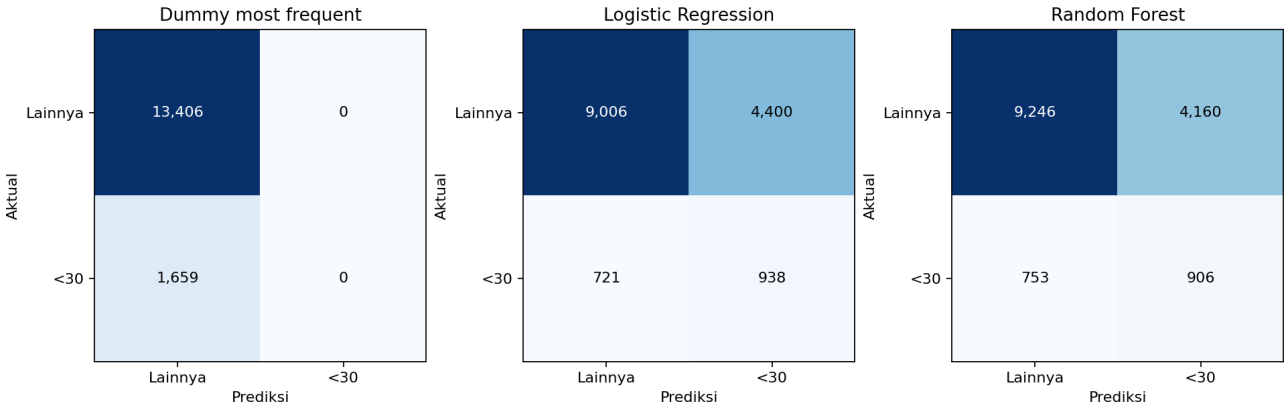
- Random Forest memiliki F1 sedikit lebih tinggi (0,2694 vs 0,2681), sedangkan Logistic Regression memiliki recall sedikit lebih tinggi (0,5654 vs 0,5461). Urutan model bergantung pada metrik.

- Precision sekitar 17-18% menunjukkan banyak prediksi positif masih salah. Meningkatnya recall belum berarti model siap digunakan dalam keputusan layanan.

- AP merangkum precision-recall dari skor probabilitas dan bukan integrasi trapezoid PR-AUC. Skor validation ini bukan skor test atau hasil validasi eksternal.

Confusion matrix dan kesalahan

07 / Kesalahan prediksi awal



Gambar 1. Confusion matrix validation. Baris = aktual, kolom = prediksi. Lainnya merupakan gabungan NO dan >30. Jumlah tiap matriks = 15.065.

Model	TN	FP	FN	TP
Baseline	13.406	0	1.659	0
Logistic Regression	9.006	4.400	721	938
Random Forest	9.246	4.160	753	906

Arti hasil

TN: kelas lainnya diprediksi lainnya. FP: kelas lainnya diprediksi <30. FN: kelas <30 terlewat. TP: kelas <30 dikenali dengan benar.

Logistic Regression mengenali 938 dari 1.659 kasus positif dan melewatkan 721, dengan 4.400 false positive. Random Forest mengenali 906 dan melewatkan 753, dengan 4.160 false positive.

Kedua model mengurangi kasus positif yang terlewat dibanding baseline, tetapi menghasilkan false positive yang besar. Trade-off ini perlu dianalisis lebih lanjut sebelum menetapkan threshold atau penggunaan praktis.

Analisis ini baru agregat. Week 12 dapat memeriksa pola kesalahan menurut kelompok usia, riwayat rawat inap dan kelompok lainnya, disertai ukuran sampel. Jangan menyatakan perbedaan kecil antarmodel sebagai bukti signifikansi tanpa pengujian yang sesuai.

Reproduksibilitas dan keluaran

08 / Menjalankan dari root repo

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
# Isi path ZIP sesuai lokasi unduhan
.\.venv\Scripts\python.exe -m src.preprocess --input "lokasi.zip"
.\.venv\Scripts\python.exe -m src.profile_data
.\.venv\Scripts\python.exe -m src.mining
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

Setelah ekstraksi pertama, preprocessing dapat dijalankan tanpa --input. Notebook pendamping: notebooks/01_preprocessing.ipynb dan notebooks/02_week11_mining.ipynb. Pilih kernel environment proyek; CLI tidak membutuhkan Jupyter.

Lokasi / berkas	Kegunaan
data/raw/	CSV dan mapping asli; tidak diubah oleh cleaning.
data/processed/diabetes/	cleaned.csv, X/y/ID tiap set, matriks NPZ, transformer joblib, schema dan metadata.
data/processed/diabetes/models/	Model joblib dan prediksi validation per baris; urutannya sama dengan y_validation dan ids_validation.
results/preprocessing/	Laporan cleaning, missing dan ringkasan transformasi.
results/week-11/	validation_metrics.csv, experiment.json, report.md dan grafik confusion matrix.

Data dan artefak disimpan lokal serta diabaikan Git; kode, dokumentasi dan laporan agregat dapat disimpan di repo. Jangan memakai ID sebagai prediktor. Muat joblib hanya dari sumber tepercaya.

Versi runtime

python 3.12.14; numpy 2.3.4; pandas 2.3.3; scipy 1.16.3; scikit_learn 1.7.2; joblib 1.5.2; Matplotlib 3.10.7.

Hash CSV asli (SHA-256):
0689e7ec031237dc63031b938805c48377748761a3b26acab621567afa24df97

Verifikasi dan tindak lanjut

09 / Pemeriksaan yang telah lolos

Pemeriksaan	Hasil
Tes perilaku preprocessing	4 tes: target/arti None/kode unknown; ID konflik; split pasien lengkap dan reproducible; statistik transformasi tidak belajar dari validation.
Tes metrik	3 tes: prediksi sempurna; baseline mayoritas tetap gagal pada positif; probabilitas invalid ditolak.
Pemeriksaan artefak	Matriks finite, dimensi fitur/label sejajar, pasien antarset terpisah dan isi data asli sama dengan arsip.
Notebook dan angka	Dua notebook berhasil dijalankan dalam mode membaca hasil. Metrik dihitung ulang dari prediksi tersimpan dan cocok dengan laporan.
Dependensi / sintaks	pip check dan compileall lolos lokal. CI diperbarui untuk tes sintetis; belum dipush atau dijalankan di GitHub untuk perubahan ini.

10 / Batas hasil dan rencana week 12

- Satu split pasien, belum CV atau tuning; threshold tetap 0,5. Hasil awal bukan evaluasi final.

- CV harus berbasis pasien dan mempelajari seleksi kolom/imputasi/encoding ulang dari bagian latih pada setiap fold. Jangan CV dari matriks yang sudah di-fit pada seluruh train.

- Lanjutkan variasi parameter dan analisis kesalahan. Test tetap disimpan sampai pilihan dibekukan; tidak memilih model atau threshold berdasarkan test.

- Split tidak temporal dan tidak menguji rumah sakit baru. Cohort masih memuat hospice/transfer lain. Fitur demografi dipertahankan; evaluasi bias dan generalisasi eksternal belum dilakukan.

Referensi dan sumber hasil

Dataset UCI, DOI 10.24432/C5230J

Dokumentasi scikit-learn 1.7: model dan metrik

Sumber lokal: docs/week-11/README.md, docs/preprocessing.md, results/preprocessing/preprocessing_summary.json, results/week-11/validation_metrics.csv dan experiment.json. Grafik diambil dari keluaran eksekusi aktual.