DATA MINING

WEEK 11: PREPROCESSING, MINING DAN EVALUASI AWAL KLASIFIKASI READMISSION PASIEN DIABETES

ANGGOTA TIM

Bambang Herlambang	5803024019
Benedictus Erlangga	5803024011
Robertus Geraldyn Alexandro Gabeler	5803024025

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS KATOLIK WIDYA MANDALA

SURABAYA

2026

01 / Tujuan dan cakupan

Menghubungkan pembacaan data, cleaning, pembagian pasien, transformasi fitur, pelatihan baseline dan dua algoritma, serta evaluasi awal. Dataset yang digunakan adalah Diabetes 130-US Hospitals for Years 1999-2008.

Komponen	Keputusan eksperimen
Unit analisis	Satu kunjungan rawat inap; pasien yang sama dapat memiliki banyak kunjungan
Target awal	<30 = 1; NO dan >30 = 0. Sasaran adalah readmission dini, bukan diagnosis diabetes
Waktu prediksi	Saat keluar rumah sakit, menggunakan informasi kunjungan yang sudah tersedia
Pembagian	Train, validation dan test berbasis pasien, seed 42
Model awal	NGBoost dan Rotation Forest; DummyClassifier prior sebagai baseline
Set evaluasi	Validation saja, 15.065 baris; modul mining tidak membaca X_test/y_test
Status hasil	Percobaan satu split dan parameter awal; belum tuning, CV atau uji final

Ringkasan hasil

Data asli terdiri dari 101.766 kunjungan. Setelah cleaning/cohort, 100.114 kunjungan dipertahankan. Pasien antarset tidak tumpang tindih. Preprocessing menghasilkan 1.222 fitur; adapter SVD menghasilkan 32 fitur kontinu untuk model.

Average precision validation: Baseline prior 0,1101; NGBoost 0,1993; Rotation Forest 0,1568. Hasil satu split awal, bukan bukti kebaruan atau kesiapan klinis.

Cleaning dan keputusan cohort

02 / Aturan yang diterapkan

Langkah	Aturan dan alasan
Pembacaan CSV	dtype=str, keep_default_na=False. Trim spasi; ? dan kosong menjadi missing. None pada hasil lab dipertahankan sebagai kategori tes tidak dilakukan.
Validasi identitas	ID kosong, target tidak dikenal, atau ID kunjungan berulang dengan isi berbeda menghentikan proses untuk review manual.
Duplikasi	Hapus baris duplikat persis bila ditemukan; pada dataset ini jumlahnya 0.
Cohort	Keluarkan kunjungan berstatus meninggal: discharge 11, 19, 20, 21 menurut IDS_mapping.csv. Ini keputusan awal proyek, bukan aturan wajib UCI.
Nilai tidak diketahui	Gender Unknown/Invalid menjadi missing. Kode administrasi tidak diketahui dinormalisasi sesuai mapping.
Fitur hitungan	Delapan fitur dikonversi numerik. Nilai negatif, non-integer atau time_in_hospital di luar 1-14 hari menghentikan proses.
Prediktor	ID pasien/kunjungan dan target asli tidak masuk X. Diagnosis dan kode administrasi tetap kategori. Nilai ekstrem valid tidak dibuang otomatis.

Dampak cleaning aktual

Pemeriksaan	Hasil
Data asli / setelah cleaning	101.766 / 100.114 baris
Kunjungan meninggal dikeluarkan	1.652
Gender invalid menjadi missing	3
Kode admission type / discharge / source menjadi missing	10.237 / 4.680 / 6.929 baris
Pasien berbeda setelah cleaning/cohort	70.439

Status hospice/transfer lain tetap dipertahankan. Kunjungan terdahulu pasien yang kemudian meninggal tidak otomatis dibuang. Perubahan cohort ini perlu dicatat saat menafsirkan hasil.

Split pasien dan transformasi

03 / Pembagian tanpa overlap pasien

Set	Baris	Pasien	Positif <30	Proporsi positif
train	70.071	49.307	7.967	11,370%
validation	15.065	10.566	1.659	11,012%
test	14.978	10.566	1.731	11,557%

GroupShuffleSplit membagi sekitar 70/15/15 persen pasien, bukan jumlah baris. Split tidak stratified dan tidak temporal. Seluruh kelas tersedia pada tiap set dan overlap pasien antarset adalah 0.

```
first = GroupShuffleSplit(
    n_splits=1, test_size=0.30, random_state=42)
train, rest = next(first.split(
    frame, groups=frame.patient_nbr))
second = GroupShuffleSplit(
    n_splits=1, test_size=0.50, random_state=42)
validation, test = next(second.split(
    frame.iloc[rest],
    groups=frame.iloc[rest].patient_nbr))
```

04 / Fit hanya pada train

Bagian	Perlakuan
Seleksi kolom	weight dibuang karena missing >50% train. acetohexamide, examide, citoglipton konstan pada train. Fitur tersisa: 43.
Numerik	Imputasi median train, kemudian StandardScaler.
Kategorikal	Imputasi __MISSING__, one-hot encoding; kategori frekuensi <10 di train digabung sebagai infrequent.
Kategori baru	Masuk kelompok infrequent jika ada, atau seluruh nol jika kelompok tersebut tidak terbentuk.
Keluaran	Matriks sparse preprocessing 1.222 kolom. Adapter SVD 32 + scaling dipelajari dari train, lalu menghasilkan fitur kontinu yang sama untuk NGBoost/Rotation Forest. Validation hanya transform.

Mining: dua algoritma utama

05 / Konfigurasi awal

Model	Konfigurasi
Baseline prior	DummyClassifier(strategy=prior). Probabilitas sama dengan prevalensi train; label prediksi tetap kelas mayoritas.
NGBoost	Bernoulli; 150 estimator; learning_rate=0,03; minibatch_frac=0,75; base DecisionTreeRegressor depth=3, min_samples_leaf=20; seed=42.
Rotation Forest	20 estimator; min_group=max_group=3; remove_proportion=0,5; n_jobs=2; seed=42.

Kedua algoritma menggunakan SVD 32 komponen dan scaling yang sama. Adapter di-fit hanya pada 70.071 baris train, bukan validation. Tidak ada pembobotan kelas atau oversampling.

```
adapter = make_feature_adapter(X_train, seed=42)
x_train = adapter.transform(X_train)
x_val = adapter.transform(X_validation)
model.fit(x_train, y_train)
probability = model.predict_proba(x_val)[:, 1]
scores = binary_metrics(y_val, probability)
```

Ruang lingkup pembandingan

SVD menyediakan masukan kontinu dan membatasi biaya komputasi. Ia dapat membuang sinyal penting; jumlah komponen dan ablasi adapter masih perlu diperiksa. Hasil LR/RF lama disimpan dalam arsip, dengan representasi serta pembobotan berbeda, sehingga bukan pembanding terkontrol.

Kebaruan penerapan NGBoost/Rotation Forest pada dataset ini belum dibuktikan. Kontribusi yang diuji adalah diskriminasi dan kalibrasi dengan protokol pasien; bukan penciptaan algoritma baru.

Evaluasi pada validation

06 / Hasil eksekusi terbaru

Metrik	Baseline prior	NGBoost	Rotation Forest
Accuracy	0,8899	0,8899	0,8876
Balanced accuracy	0,5000	0,5000	0,5077
Precision positif	0,0000	0,0000	0,3301
Recall positif	0,0000	0,0000	0,0205
F1 positif	0,0000	0,0000	0,0386
ROC-AUC	0,5000	0,6417	0,5932
Average precision	0,1101	0,1993	0,1568
Brier score	0,0980	0,0948	0,1010
Log loss	0,3468	0,3329	0,6968

Validation: 15.065 baris, 1.659 positif <30 (11,012%). Threshold 0,5 tetap; parameter belum dituning. Precision/recall/F1 mengacu kelas positif. Test belum dievaluasi.

Interpretasi

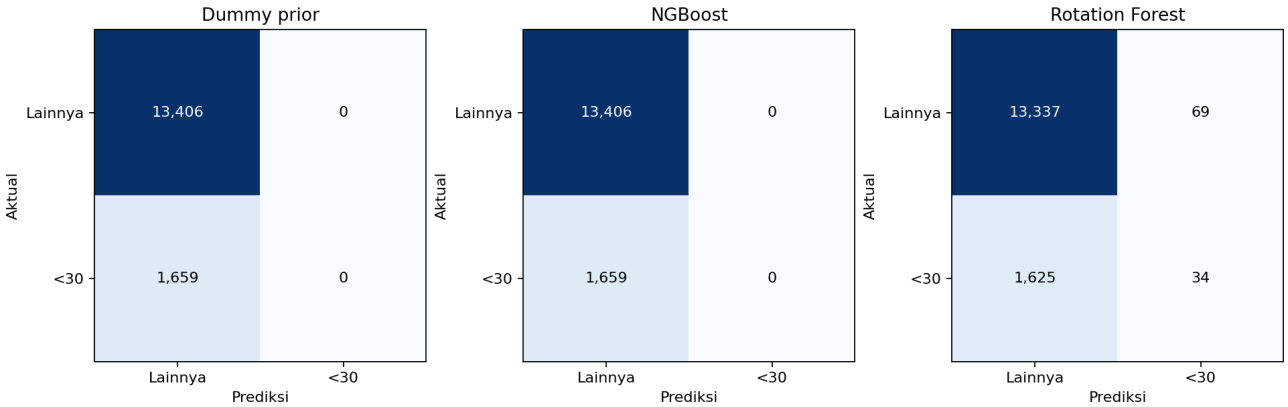
AP tertinggi pada percobaan ini: NGBoost (0,1993). AP/ROC-AUC lebih besar lebih baik; Brier score/log loss lebih kecil lebih baik. Metrik harus dibaca bersama.

Model dapat meranking risiko lebih baik daripada baseline tetapi tetap jarang memprediksi positif pada threshold 0,5. Periksa TP/FN dan jangan menyamakan akurasi mayoritas dengan deteksi readmission dini. Threshold operasional belum dipilih.

Hasil ini satu split awal, bukan hasil CV, uji final atau validasi eksternal. Model probabilistik tidak otomatis menghasilkan probabilitas terkalibrasi.

Confusion matrix validation

07 / Kesalahan prediksi



Baris = aktual; kolom = prediksi. Lainnya adalah NO dan >30. Tiap matriks memuat 15.065 kunjungan.

Model	TN	FP	FN	TP
Baseline prior	13.406	0	1.659	0
NGBoost	13.406	0	1.659	0
Rotation Forest	13.337	69	1.625	34

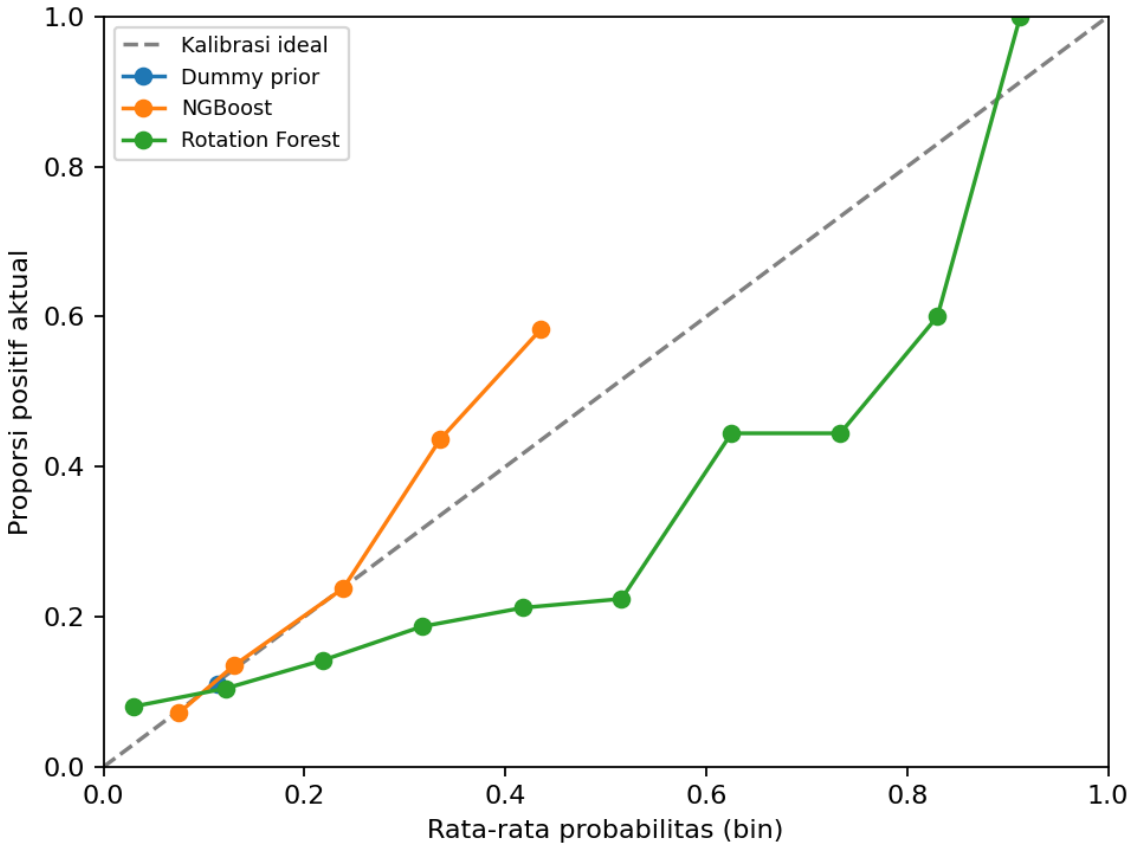
NGBoost mengenali 0 kasus positif dan melewatkan 1.659, dengan 0 false positive pada threshold 0,5.

Rotation Forest mengenali 34 kasus positif dan melewatkan 1.625, dengan 69 false positive pada threshold 0,5.

Analisis lebih rinci menurut usia/riwayat rawat inap dan evaluasi trade-off threshold dapat dilanjutkan. Gunakan validation atau CV yang benar, bukan memilih threshold dari test.

Kalibrasi probabilitas

08 / Reliability diagram



Sepuluh bin probabilitas sama lebar; bin kosong tidak ditampilkan. Garis diagonal menunjukkan kalibrasi ideal. Jumlah sampel setiap bin dicatat di validation_calibration.csv.

Kurva menunjukkan kesesuaian rata-rata probabilitas dengan proporsi positif aktual pada validation. Bin kecil dapat tidak stabil; kurva saja bukan bukti model sudah terkalibrasi. Belum dilakukan kalibrasi pascatraining.

SVD menjelaskan 76.10% variasi fitur train. Angka ini bukan persentase informasi target yang dipertahankan atau bukti kualitas model.

Reproduksibilitas dan keluaran

09 / Menjalankan dari root repo

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
# Isi path ZIP sesuai lokasi unduhan
.\.venv\Scripts\python.exe -m src.preprocess --input "lokasi.zip"
.\.venv\Scripts\python.exe -m src.profile_data
.\.venv\Scripts\python.exe -m src.mining
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

Setelah ekstraksi pertama, preprocessing dapat dijalankan tanpa --input. Notebook pendamping: notebooks/01_preprocessing.ipynb dan notebooks/02_week11_mining.ipynb. Pilih kernel environment proyek; CLI tidak membutuhkan Jupyter.

Lokasi / berkas	Kegunaan
data/raw/	CSV dan mapping asli; tidak diubah oleh cleaning.
data/processed/diabetes/	cleaned.csv, X/y/ID tiap set, matriks NPZ, transformer joblib, schema dan metadata.
data/processed/diabetes/models_paper/	Model joblib, feature_adapter.joblib dan prediksi validation; urutan sama dengan y_validation dan ids_validation.
results/preprocessing/	Laporan cleaning, missing dan ringkasan transformasi.
results/week-11/	validation_metrics.csv, experiment.json, report.md dan grafik confusion matrix.

Data dan artefak disimpan lokal serta diabaikan Git; kode, dokumentasi dan laporan agregat dapat disimpan di repo. Jangan memakai ID sebagai prediktor. Muat joblib hanya dari sumber tepercaya.

Versi runtime

python 3.12.14; numpy 2.3.4; pandas 2.3.3; scipy 1.16.3; scikit_learn 1.7.2; joblib 1.5.2; Matplotlib 3.10.7; ngboost 0.5.11; aeon 1.6.0.

Hash CSV asli (SHA-256):
0689e7ec031237dc63031b938805c48377748761a3b26acab621567afa24df97

Verifikasi dan tindak lanjut

10 / Pemeriksaan yang telah lolos

Pemeriksaan	Hasil
Tes perilaku preprocessing	4 tes: target/arti None/kode unknown; ID konflik; split pasien lengkap dan reproducible; statistik transformasi tidak belajar dari validation.
Tes metrik/model	7 tes: metrik sempurna/mayoritas, input invalid, bin kalibrasi, adapter train-only, probabilitas model baru dan alur lengkap tanpa file test. Total dengan preprocessing: 11 tes.
Pemeriksaan artefak	Matriks finite, dimensi fitur/label sejajar, pasien antarset terpisah dan isi data asli sama dengan arsip.
Notebook dan angka	Dua notebook berhasil dijalankan dalam mode membaca hasil. Metrik dihitung ulang dari prediksi tersimpan dan cocok dengan laporan.
Dependensi / sintaks	pip check dan compileall lolos lokal. CI menguji preprocessing, metrik dan model kecil sintetis, bukan training dataset penuh. Status CI mengikuti commit di GitHub.

11 / Batas hasil dan rencana week 12

- Satu split pasien, belum CV atau tuning; threshold tetap 0,5. Hasil awal bukan evaluasi final.

- CV harus berbasis pasien dan mempelajari seleksi kolom/imputasi/encoding ulang dari bagian latih pada setiap fold. Jangan CV dari matriks yang sudah di-fit pada seluruh train.

- Lanjutkan variasi parameter, ablasi adapter SVD, kalibrasi dan analisis kesalahan. Test tetap disimpan sampai pilihan dibekukan; tidak memilih model atau threshold berdasarkan test.

- Split tidak temporal dan tidak menguji rumah sakit baru. Cohort masih memuat hospice/transfer lain. Fitur demografi dipertahankan; evaluasi bias dan generalisasi eksternal belum dilakukan.

Referensi dan sumber hasil

Dataset UCI, DOI 10.24432/C5230J

Dokumentasi scikit-learn 1.7: model dan metrik

Sumber lokal: docs/week-11/README.md, docs/preprocessing.md, results/preprocessing/preprocessing_summary.json, results/week-11/validation_metrics.csv dan experiment.json. Grafik diambil dari keluaran eksekusi aktual.